# 海量数据处理爬虫作业



## 作业要求

- 搜寻“不同标准的”“最好用”的开源爬虫库及软件
  - 请自定义“最好用”，请记录搜索过程，以及搜索结果，以及你自己的分析结论
- 尝试爬取自己感兴趣的数据

## 常用爬虫库分析

### 爬虫资料搜集

对于时间精力有限的小白来说，想要在最短的时间内搜寻到各类开源爬虫库及软件，最好的办法就是将前人（多指技术大牛）已经写好的总结性文章找出来，然后加以自己的想法，得到最终的结果。

根据经验，这些总结性的文章一定存在于**各类优质技术内容生产及分享平台**，比如**github**，**知乎**，**CSDN**，**cnblogs**，其余网站水平层次不齐，且有较高概率是从上述平台转载（抄）过来的。因此在搜索过程中，为了提高搜索的效率及结果的质量，我只收集上述网站的内容，其余网站不看。

为了找到这些优质内容所在的具体页面，将关键字输入搜索引擎。这里的关键字使用“**开源 爬虫 库 框架 软件**”，同时为了提高搜索的多样性，同时使用百度和谷歌。

大体的搜索过程如下图：


### 爬虫流程分析

阅读这些优质内容，我大致了解了爬虫**较为常见**的流程：

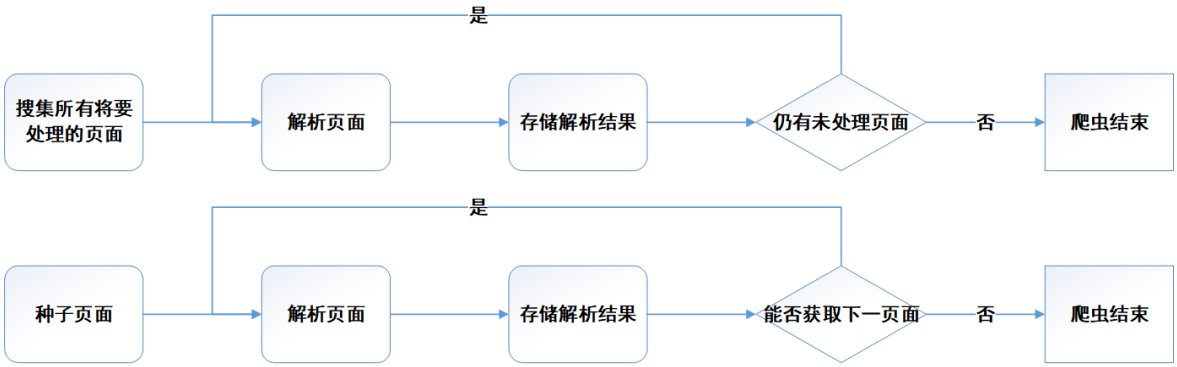


但无论是何种流程，无论如何绕不开的有2个阶段：**获取页面**，**解析页面。**

- 获取页面，首先要获得该页面的URL，然后通过互联网得到该页面的代码，这其中涉及到网络中的各类协议。
- 解析页面，网络获取的页面一般是XML类型的文件，解析页面就是分析其中的字符串，而各类字符串的分析逻辑较为复杂，无论何种高级程序语言处理起来都很棘手。

## 常用爬虫工具

如果一个人不借助于第三方库，直接从头开始写，那不论是对小白还是技术大牛都是极为繁琐的。因此封装了各类处理方法的库就在这个过程中诞生了，有了这些库，处理上述问题的过程就被大大简化了，而且也无需了解底层的处理逻辑和实现细节，只需要知道输入输出是什么即可。

- 用于**获取页面**的库：
  - **urllib**、**requests**、urllib2、urllib3、grab、pycurl、httplib2、RoboBrowser
- 用于**解析页面**的库：
  - **beautifulsoup**、**lxml**、**re**、cssselect

为了实现整个爬虫，可以**自由组合**上面的库，例如**urllib+beautifulsoup**、**urllib+lxml**、**urllib+re**、**requests+re**

当然也有提供**一整条龙服务**的框架，**scrapy**、**pyspider**、**nutch**

甚至有专门的软件：八爪鱼采集器、后羿采集器、火车头（由于爬虫软件对提高编程能力几乎没有帮助，后面不再提及）

## 自定义“最好用”的爬虫工具

至于什么是最好用的，任何一种定义式的结论都不具备普遍意义。因此，我觉得要对不同的用户来看。

- 对于企业：企业的目的是赚钱，所以那么采用何种方法，必定要结合企业自身的情况来对爬虫中的各项指标进行综合分析，如**稳定性、多线程、分布式、速度、开发成本**等等进行选择。因此对于企业，**“最好用”——企业利益最大化**
- 对于个人，如果是技术大牛，那**“最好用”——功能齐全**；如果是小白，“**最好用”——上手容易。**
- 对于我自己，顺手就好。那怎么才是顺手呢？得试过了才知道。

因此我尝试使用**nutch**、**requests+beautifulsoup**，**scrapy**分别实现爬取**人民文学出版社的书籍：要求获取书名、ISBN、号码、销售网站及当前价格**

在爬取前先要分析人民文学出版社的网页，首先要爬取图书列表上的所有图书的详细信息URL，虽然图书列表被分为多页，但是每一页都是静态页面，很容易就能推算出每一页的URL，进而爬取所有的图书详细地址；随后就是循环爬取每一本书的内容。


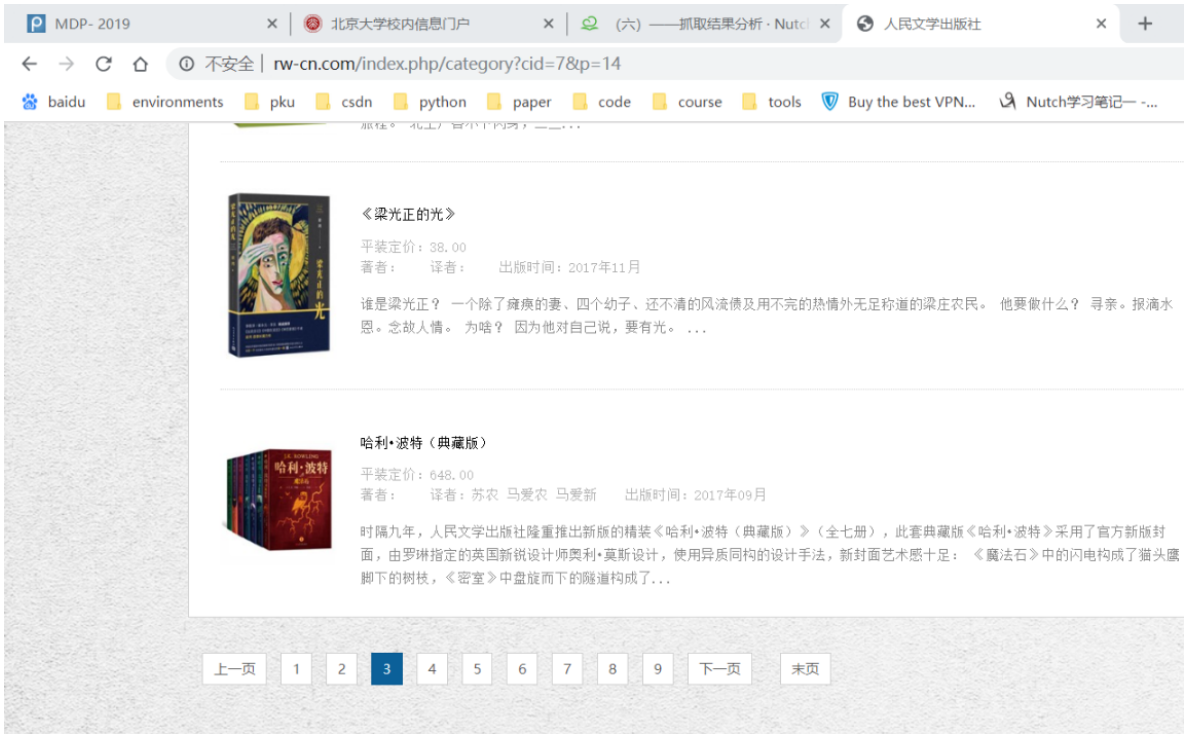


**nutch**

nutch环境安装是真的繁琐，在虚拟机上折腾了一天半，占据了做本次作业一半以上的时间好不容易安装上了，结果按着教程却怎么也出不来结果。

结论：nutch虽然功能强大，但是对于我这样仅仅是了解入门爬取网页的人来说，学习成本太高。

PS：百度上能找到的nutch教程都比较坑，尤其是在ant编译阶段，基本上都得卡住。这里给出我成功安装上的教程：https://www.cnblogs.com/huligong1234/p/3464371.html

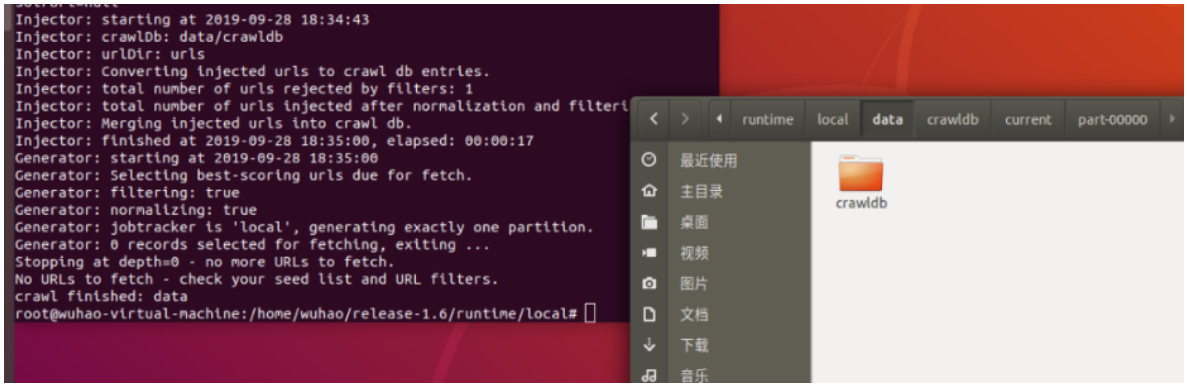


**requests+beautifulsoup**

```
# !/usr/bin/env python
# coding:utf-8
# Author: WuHao

from bs4 import BeautifulSoup
import requests
import time

start_time = time.time()
urlmodel = "http://www.rw-cn.com/index.php/category?cid=7&p="
urllist = []

print("正在获取所有图书URL")
for i in range(0, 6749, 7):
    urlcur = urlmodel + str(i)
    f = requests.get(urlcur)  # Get该网页从而获取该html内容
    soup = BeautifulSoup(f.content, "lxml")
    for j in soup.find_all('a', class_='a_7 fl'):
        urllist.append(j['href'])

fd = open('book.txt', 'w', encoding='utf-8')
for i,url in enumerate(urllist):
    print("正在分析第%d页" % i)
    f = requests.get(url)  # Get该网页从而获取该html内容
    soup = BeautifulSoup(f.content, "lxml")  # 用lxml解析器解析该网页的内容, 好像
f.text也是返回的html

    for j in soup.find_all('h2', class_='h_10'):
        # print(j.text)
        name=j.text.split()[0]
        price=j.text.split()[1]
        for k in soup.find_all('div', class_='div_47 fix'):  # ,找到div并且class为
pl2的标签
            a = k.find_all('span')  # 在每个对应div标签下找span标签，会发现，一个a里面
有四组span
            isbn=a[1].text.replace('ISBN：','')
            fd.write('书名：'+name+ '\n')
            fd.write('ISBN号码：' + isbn + '\n')
            fd.write('当前价格：' + price + '\n')
            fd.write('销售网站：' + url+ '\n')
        fd.write('----------------------------------------\n')

fd.close()
end_time=time.time()
```

```
print("耗时："+ str(int((end_time-start_time)/60)) + '分' + str(int((end_time-start_time)%60)) + '秒\n')
```

运行过程和结果如下，耗时27分12秒。

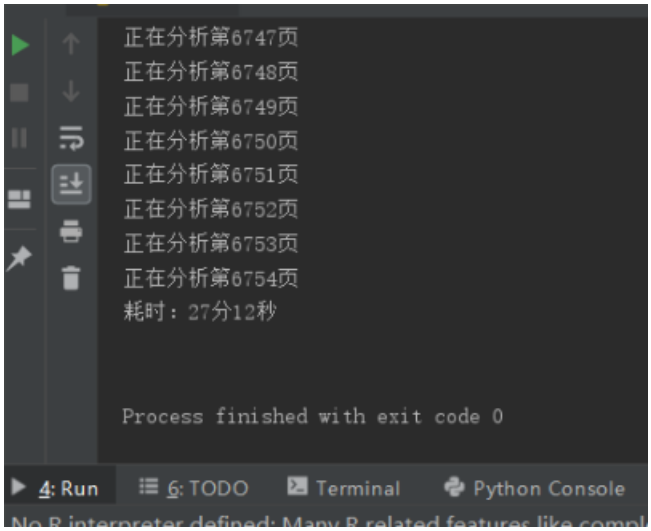


book.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
书名：应物兄
ISBN号码：9787020147465
当前价格：75.00元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7370
----------------------------------------
书名：牵风记
ISBN号码：9787020148240
当前价格：43.00元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7367
----------------------------------------
书名：《世间生活》
ISBN号码：9787020151967
当前价格：元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7388
----------------------------------------
书名：《抑郁生花》
ISBN号码：9787020151820
当前价格：42元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7387
----------------------------------------
书名：《辛格自选集》
ISBN号码： 9787020141210
当前价格：89.0元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7386
----------------------------------------
书名：《穗子的动物园》
ISBN号码：978-7-02-015136-3
当前价格：58元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7384
----------------------------------------
书名：《耶稣的学生时代》
ISBN号码：9787020149421
```

结论：灵活，流程逻辑清晰，上手难度低。（完整代码及结果）

**scrapy**

文件结构：

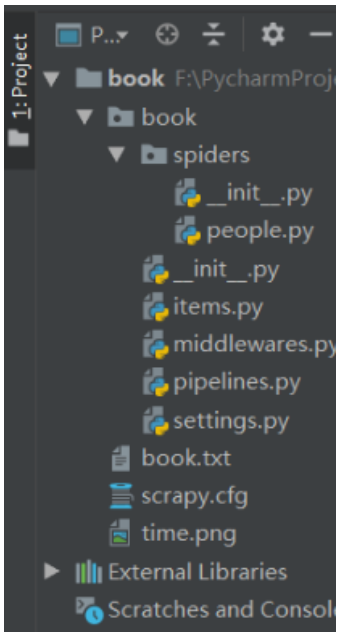


people.py

```
# !/usr/bin/env python
# coding:utf-8
# Author: WuHao

import scrapy
from book.items import BookItem


class PeopleSpider(scrapy.Spider):
    name = 'people'
    start_urls = ['http://www.rw-cn.com/index.php/category?cid=7&p={}'.format(i)
for i in range(0,6749,7)]

    def parse(self, response):
        if 'cid' in response.url:
            urls=response.xpath('//a[@class="a_7 fl"]/@href').extract()
            for url in urls:
                yield scrapy.Request(url)
        elif 'view' in response.url:
            item = BookItem()
            item['name']=response.xpath('//h2[@class="h_10"]/text()').extract()
[0].replace('\t', '')

 item['price']=response.xpath('//h2[@class="h_10"]/span/text()').extract()[0]
            item['isbn'] =response.xpath('//div[@class="div_47
fix"]/span/text()').extract()[1].replace('ISBN：','')
            item['url']=response.url
            yield item
```

运行过程和结果如下，耗时15分59秒。

```
'downloader/response_status_count/200': 7720,
'downloader/response_status_count/404': 1,
'elapsed_time_seconds': 958.576012,
'finish_reason': 'finished',
'finish_time': datetime.datetime(2019, 9, 26, 10, 47, 56, 201235),
'item_scraped_count': 6755,
'log_count/DEBUG': 14476,
'log_count/INFO': 25,
'request_depth_max': 1,
'response_received_count': 7721,
'robotstxt/request_count': 1,
'robotstxt/response_count': 1,
'robotstxt/response_status_count/404': 1,
'scheduler/dequeued': 7720,
'scheduler/dequeued/memory': 7720,
'scheduler/enqueued': 7720,
'scheduler/enqueued/memory': 7720,
'start_time': datetime.datetime(2019, 9, 26, 10, 31, 57, 625223)}
2019-09-26 18:47:56 [scrapy.core.engine] INFO: Spider closed (finished)
```

book.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
书名：《耶稣的学生时代》
ISBN号码：9787020149421
当前价格： 58元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7383
----------------------------------------
书名：《燕子最后飞去了哪里》
ISBN号码：9787020122257
当前价格：43.00元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7297
----------------------------------------
书名：《彩色面纱》
ISBN号码：
当前价格：￥36.00元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7253
----------------------------------------
书名：哈利•波特（典藏版）
ISBN号码：9787020127993
当前价格：648.00元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7331
----------------------------------------
书名：《吃鲷鱼让我打嗝》
ISBN号码：9787020120963
当前价格：49.00元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7290
----------------------------------------
书名：《湮没的时尚•花想容》
ISBN号码：9787020114849
当前价格：元
销售网站：http://www.rw-cn.com/index.php/category/view?id=7312
----------------------------------------
书名：《周涛散文》
ISBN号码：978-7-02-010815-2
```

结论：上手难度中等，缺点是，url页面的获取顺序是不确定的，每次运行程序得到的爬虫结果均不一样。（完整代码及结果）

**综上，我觉得最好用的是requests+beautifulsoup(或lxml)**

# 爬取自己感兴趣的数据

## 利用selenium爬取动态网页

爬取人民文学出版社是比较容易的，毕竟可以通过地址推算出所有的图书列表网址，进而获取每一本图书的详细地址信息。然而北京大学出版社的图书列表是动态的，每一页的地址都是相同的，那么此时继续使用人民文学出版社时的方法就失效了。

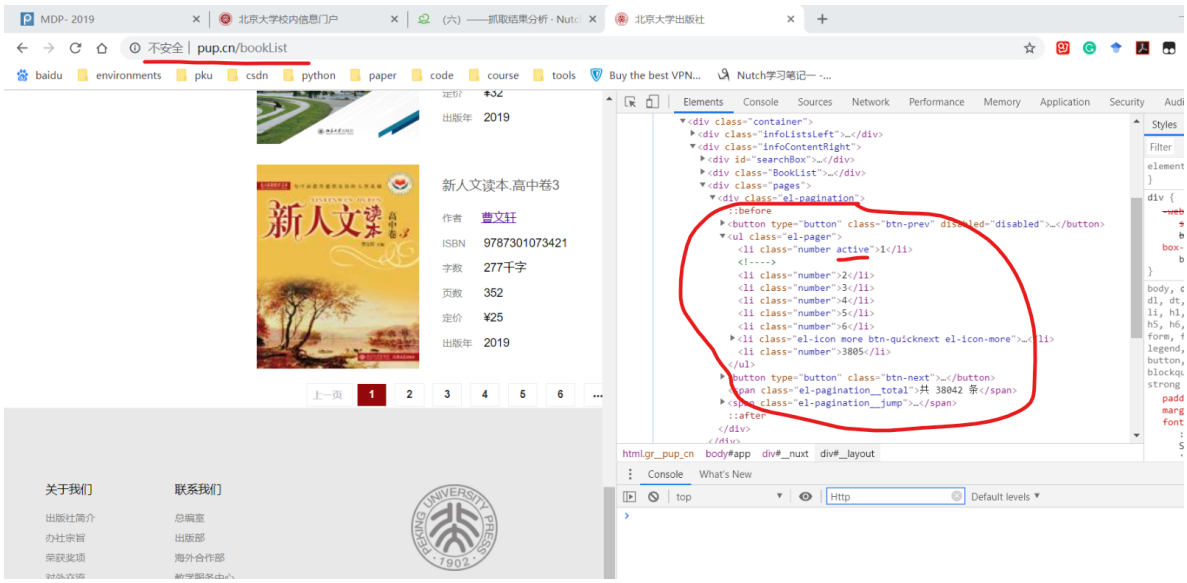


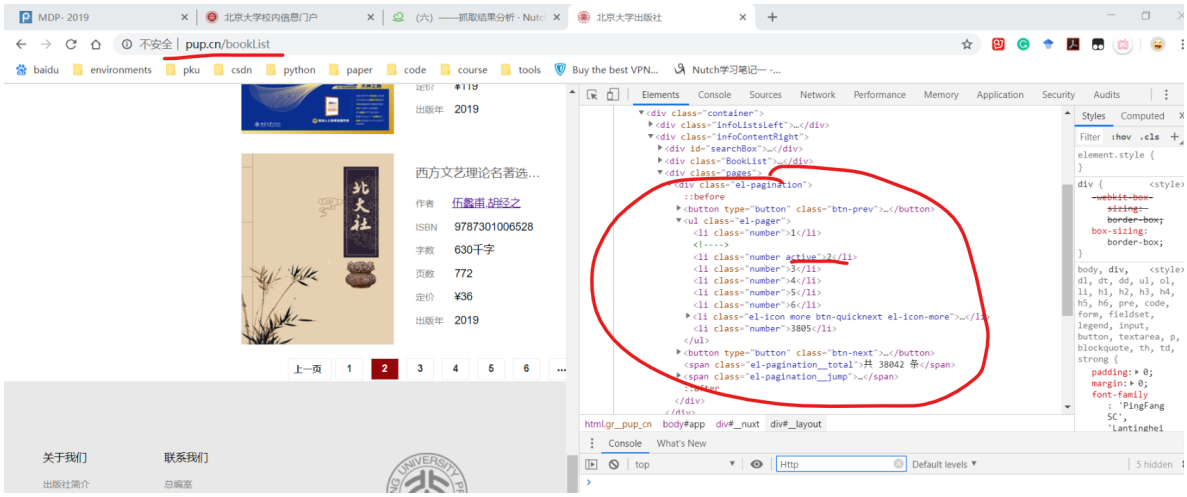


针对动态网页，selenium可以模拟浏览器动作，自动点击下一页按钮。

```
def turn_page(self):
        try:
            self.wait.until(EC.element_to_be_clickable((By.XPATH,
'//button[@type="button" and\
             @class="btn-next"]'))).click()
            time.sleep(1)

 self.browser.execute_script("window.scrollTo(0,document.body.scrollHeight)")
            time.sleep(2)
        except selenium.common.exceptions.NoSuchElementException:
            self.isLast = True
        except selenium.common.exceptions.TimeoutException:
            print('turn_page: TimeoutException')
            self.isLast = True
        except selenium.common.exceptions.StaleElementReferenceException:
```

```
            print('turn_page: StaleElementReferenceException')
            self.browser.refresh()
```

此处有程序执行时的屏幕录制，里面有模拟浏览器的动作 https://www.bilibili.com/video/av69082404。（完整代码及结果）

**注：由于图书总量太多，此处只爬取北京大学出版社2019年出版的图书**

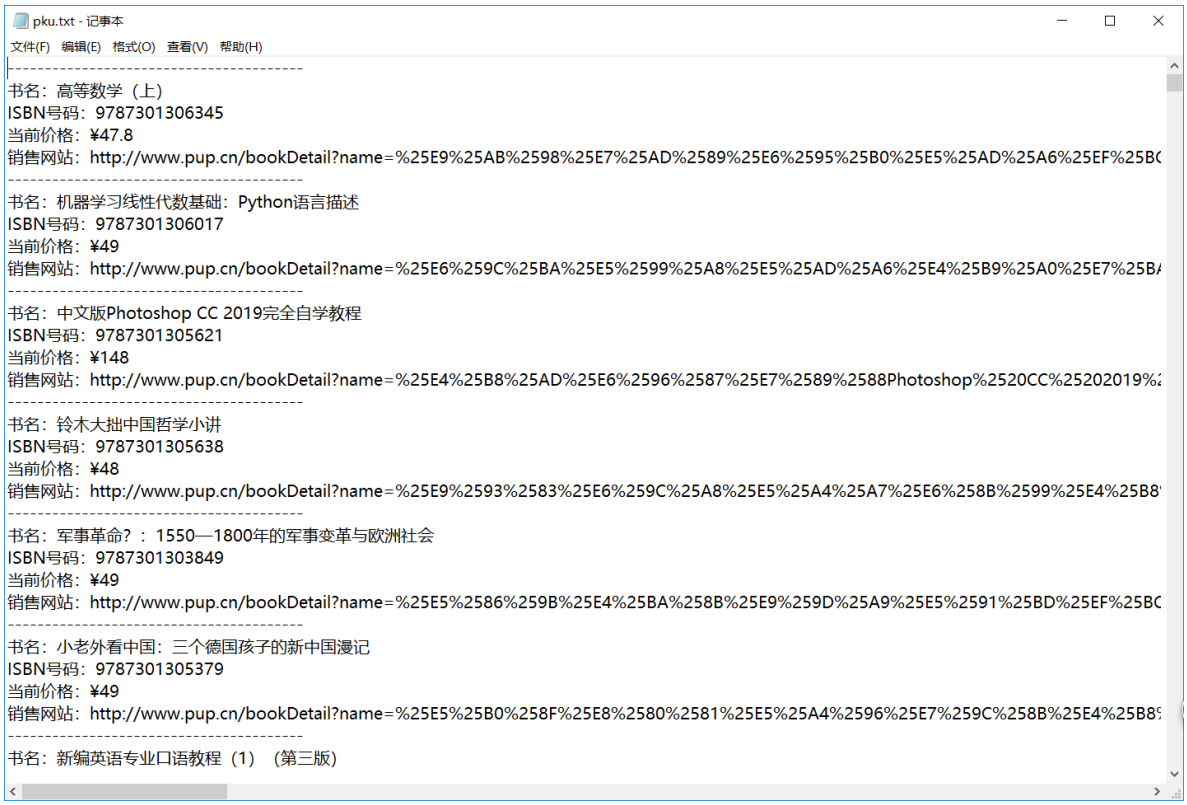


## requests+lxml+cookie模拟登录

爬取豆瓣上《上海堡垒》的所有差评，因为豆瓣的权限限制，非登录用户只能查看10页评论，因此这里需要在请求包的头部手动添加cookie，以模拟登录用户。（豆瓣的URL和页面分析向来简单，此处不再赘述）

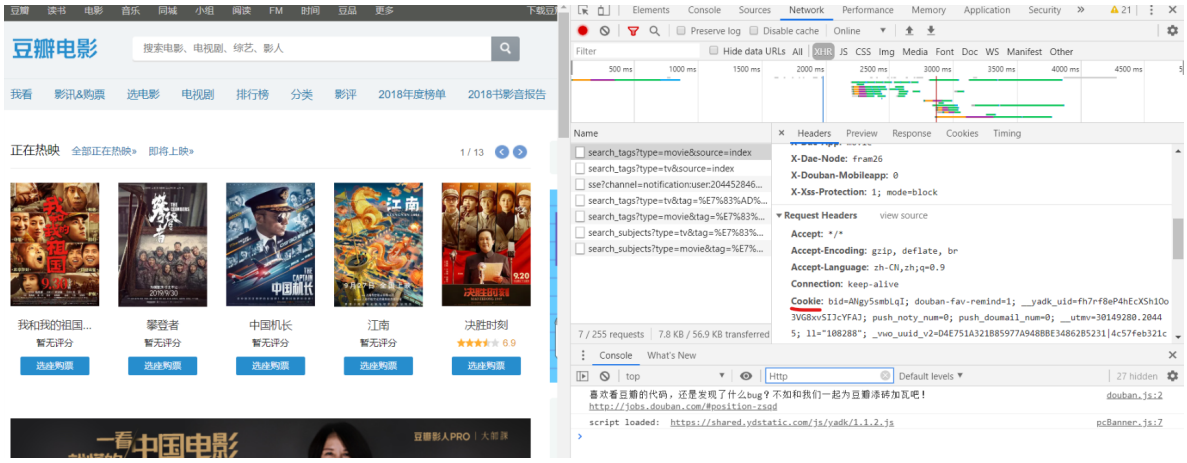

```python
# 获取网页源代码
def get_page(url):
    headers = {
        'USER-AGENT':'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/67.0.3396.99 Safari/537.36',
        'Cookie':'My Cookie'
    }
    response = requests.get(url=url,headers=headers)
    html = response.text
    return html
```


(完整代码及结果)